

Тестовое задание: аналитик данных в DaData

Справочник «ИНН → сайт организации». Репозиторий с кодом (Задание 2): <https://github.com/USER/dadata-site-finder>

Задание 1. Как собрать и поддерживать справочник

1. Постановка и допущения

- **Объекты:** действующие юрлица и ИП из ЕГРЮЛ/ЕГРИП (по порядку величины 3 млн ЮЛ и 4 млн ИП). Филиалы — по ИНН головной организации.
- **Сайт организации** — домен, который она контролирует и на котором выступает владельцем, продавцом или исполнителем. Не считаются: карточки на агрегаторах и картах, страницы в соцсетях, магазины на маркетплейсах, поддомены конструкторов (*.tilda.ws). Сайт группы компаний засчитывается, если на нём указаны реквизиты именно этой организации.
- **Формат ответа:** список доменов, основной первым — как поле `data.sites[]` в ответе «Организация по ИНН».
- **Главная метрика — точность (precision).** Справочник используют для проверки контрагентов, обогащения CRM, антифрода: неверный сайт в ответе вреднее пустого поля. Полнота (recall) — вторая по важности.

2. Способы сбора данных

Способ	Как работает	За	Против
1. Обход доменов (домен → ИНН)	Все домены зон .ru/.рф/.su (списки зон, порядка 6 млн) + новые домены из СТ-логов. Качаем главную и «Контакты / Реквизиты / Политику ПДн», извлекаем ИНН/ОГРН.	ИНН публикует сама компания — высокая точность. Продавцы обязаны указывать наименование и ОГРН (ЗоЗПП), операторы ПДн — реквизиты в политике (152-ФЗ). Стоимость зависит от числа доменов, а не организаций.	Своя инфраструктура обхода. ИНН встречается и на чужих сайтах (политики ПДн с перечнем третьих лиц, «наши клиенты»): нужна классификация контекста. Не находит сайты без реквизитов.
2. Открытые реестры с полем «сайт»	ЕИС закупки, раскрытие информации эмитентов, реестры ЦБ (банки, страховщики, МФО), реестр аккредитованных ИТ-компаний, реестры лицензий.	Официальные данные, дёшево, высокая точность.	Малая и смещённая доля: в основном крупные и регулируемые организации.
3. Домен корпоративной почты	E-mail из ЕГРЮЛ/контактов DaData (заполнен у ~50% действующих компаний): <code>info@firma.ru</code> → <code>firma.ru</code> .	Данные уже есть, почти бесплатно.	Бесплатные почтовые сервисы неинформативны. Почтовый домен — не всегда сайт (сайта нет, домен бухгалтера или хостера). Сильный кандидат, но не доказательство.
4. Поиск + LLM (Задание 2)	Поиск по ИНН, ОГРН и названию, проверка найденных сайтов, решение LLM по спорным случаям.	Закрывает «хвост»: сайты без ИНН, бренды, не совпадающие с юрназванием.	Стоимость и время на каждый ИНН, зависимость от индекса поисковика. На 7 млн ИНН дорого.
5. Агрегаторы и карты (Rusprofile, 2ГИС, Яндекс Бизнес)	Покупка данных, партнёрство или парсинг.	Большое покрытие.	Вторичные данные с ошибками; права изготовителя базы данных (ст. 1334 ГК РФ) и условия использования; часть агрегаторов скрывает поле «сайт».

6. WHOIS/RDAP	Для доменов .ru/.рф, зарегистрированных на организацию, указывается её наименование.	Независимый сигнал владения доменом.	Только название, без ИНН; доступ ограничен.
---------------	--	--------------------------------------	---

Выбор. Ни один способ не даёт одновременно покрытие и точность. Поэтому архитектура — «кандидаты из нескольких источников → единая проверка → решение по доказательствам»:

1. **Генерация кандидатов.** Основной массовый источник — обход доменов (1). Дополняют: домены почты (3), реестры (2), поле «сайт» агрегаторов (5) — только как кандидат, не как истина.
2. **Единая проверка** для всех источников (реализована в Задании 2): загрузка сайта, поиск ИНН/ОГРН/названия, определение контекста — это реквизиты владельца сайта или упоминание третьего лица. LLM — только для неоднозначных случаев.
3. **Решение по уровню доказательства, а не по «вероятности»:** А — ИНН/ОГРН на сайте в роли владельца; В — название + адрес/телефон на сайте + независимый источник (почта, реестр, агрегатор); С — только совпадение названия → не публикуется.
4. **Поиск + LLM (4)** — только для дозаполнения: ИНН, которые часто запрашивают в API, но сайт для них не найден способами 1–3. Дорогой метод тратится там, где результат видят клиенты.

Почему основа — обход доменов: стоимость пропорциональна числу доменов, а не организаций; доказательство берётся из данных самой компании; процесс детерминирован и воспроизводим. Проверка на выборках Задания 2: ИНН или ОГРН нашёлся на собственном сайте у 12 из 21 крупной компании (реквизиты спрятаны в разделах для инвесторов, сайты закрыты от ботов) и у 42 из 43 малых компаний и ИП. Вторая цифра — верхняя оценка: малые компании отбирались через страницы реквизитов. Вывод: для малого бизнеса реквизиты на сайте — основной сигнал, для крупных компаний нужны дополнительные (название + независимый источник).

3. Анализ и оценка качества

• Метрики:

- *precision* — доля верных доменов среди опубликованных;
- *recall* — доля найденных среди организаций, у которых сайт есть;
- *coverage* — доля ИНН с непустым ответом.

Все метрики считаются в разрезах: ЮЛ/ИП, размер (выручка, численность), регион, ОКВЭД, возраст компании, источник, уровень доказательства. Отдельно — с весами по частоте запросов ИНН в API, чтобы мерить качество там, где его видят клиенты.

• Эталон:

- стратифицированная случайная выборка из ЕГРЮЛ/ЕГРИП, 1–2 тыс. ИНН, с перевесом редких страт и весами для пересчёта на генеральную совокупность;
- разметка двумя ассессорами по инструкции (определение сайта, спорные случаи), согласованность по каппе Коэна, арбитраж;
- метка «не удалось установить» (сайт скрыт, противоречивые данные) исключается из метрик и учитывается отдельно.

- **Дешёвая оценка *precision*:** отдельная выборка из опубликованных ответов. Проверить, что сайт верный, проще, чем найти его с нуля. На 1000 ответах 95%-й доверительный интервал (Уилсон) — около $\pm 1,5$ п.п. при *precision* 95%.

- **Калибровка:** для каждого уровня доказательства (А/В) измеряем *precision*. Публикуем только уровни, которые дотягивают до целевого порога (например, 95%).

- **Ловушка — смещение эталона.** Если положительные примеры набирать через страницы реквизитов, у всех них ИНН на сайте есть, и *recall* для сайтов без реквизитов окажется завышен. В Задании 2 так набрана часть выборки; это учтено при интерпретации результатов.

• В эксплуатации:

- ежемесячный аудит случайной выборки опубликованных записей;
- мониторинг доли «мёртвых» доменов, изменившихся ответов и жалоб клиентов;
- канал «сообщить об ошибке» в API или личном кабинете.

4. Поддержание актуальности

- **Модель данных:**
 - ИНН, домен, источник, уровень доказательства;
 - URL страницы и фрагмент с доказательством;
 - `first_seen`, `last_verified`, статус (активен / не отвечает / снят), история изменений.
- **Проверка по событиям:**
 - *ЕГРЮЛ*: ликвидация → снять связь; реорганизация → проверить правопреемника; смена названия или адреса → перепроверить;
 - *домен*: смена регистранта, снятие с делегирования, истечение срока регистрации → перепроверить. Истёкший домен могут перекупить, и под старой связью окажется чужой сайт;
 - *сайт*: ИНН исчез со страниц, появился редирект на другой домен → перепроверить;
 - *новые домены*: ежедневные изменения зон и СТ-логи → обход.
- **Плановые проверки:**
 - доступность (DNS/HTTP) — еженедельно;
 - полная перепроверка реквизитов — раз в 1–3 месяца, для популярных ИНН — чаще;
 - отрицательные ответы («сайта нет») — повторная проверка через 1–3 месяца (в прототипе — через 30 дней).
- **Снятие связи:** после нескольких неудачных проверок подряд — статус «не отвечает»; через N недель — удаление из ответа API (в истории запись остаётся).

5. Открытые вопросы, проблемы и ограничения

- **Что считать основным сайтом:**
 - холдинги (один сайт — много ИНН);
 - сети и бренды (один ИНН — много сайтов);
 - дилеры и франчайзи (сайт дилера под брендом производителя).
- Нужны продуктовые правила и тест-кейсы.
- **Площадки:** для малого бизнеса единственным присутствием в сети часто бывает магазин на маркетплейсе, страница VK или Telegram. Решение: отдельные поля (`social`, `marketplaces`), а не смешивание с `sites`.
 - **ИП:**
 - связка «физлицо — сайт» — это персональные данные: нужно правовое основание обработки и процесс удаления по запросу;
 - покрытие ниже: сайт у ИП бывает реже, а ФИО — неуникальный ключ для поиска.
 - **Мошеннические клоны** копируют реквизиты настоящих компаний, поэтому «ИНН на сайте» ещё не означает «сайт компании». Сигналы подделки: молодой домен, другое название в WHOIS, контакты не совпадают с ЕГРЮЛ, несколько доменов претендуют на один ИНН. При таких сигналах связь уходит на ручную проверку.
 - **Юридические риски сбора:** условия использования агрегаторов, права изготовителя базы данных, `robots.txt` и нагрузка на сайты при обходе.
 - **Технические:**
 - защита от ботов и сайты, которые рендерятся только JavaScript-ом;
 - сайты в иностранных зонах (`.com`, `.io`) нельзя перечислить заранее — их находим только через поиск и СТ-логи.
 - **LLM:**
 - стоимость и недетерминированность;
 - контентные фильтры: в Задании 2 GigaChat отказывался отвечать на пакетах кандидатов, где встречались страницы о санкциях;
 - риск галлюцинаций. Поэтому решение принимает правило, а LLM даёт только категорию и цитату, которую проверяет код.

- **Экономика:** ключевая метрика — стоимость одной подтверждённой связи по каждому источнику. Дорогие методы применяем только к востребованным ИНН.

Задание 2. Пайплайн «ИНН → сайт» (Web Search + LLM)

Код: <https://github.com/USER/dadata-site-finder>. Python 3.12, запуск: `uv run python -m site_finder 7721581040`
→ `{"domain": "dadata.ru", "sites": ["dadata.ru"]}`. `domain` — основной сайт (формат из задания) или `null`; `sites` — все подтверждённые домены (совместимо с `data.sites[]`).

Общая логика

Это workflow с агентным шагом, а не автономный агент. Шаги задаёт код. LLM принимает решения в двух местах: оценивает каждый найденный сайт и, если подтверждённого сайта нет, сама формулирует новые поисковые запросы. Принцип: **доказательства собирает код, LLM интерпретирует контекст, решение принимает прозрачное правило.**

ИНН → валидация → справочник `data/directory.csv` (уже проверяли? → ответ)
→ карточка ЕГРЮЛ/ЕГРИП: название, ОГРН, адрес, e-mail
→ поиск Еха + DuckDuckGo: "ИНН" · "ОГРН" · название + город (ИП: ФИО + город)
→ кандидаты: домены из выдачи + домены со страниц с ИНН компании (агрегаторы:
 «Сайт: ...», «E-mail: info@...») + домен почты из ЕГРЮЛ
→ проверка кодом: главная, Реквизиты/Контакты/О компании/Политика ПДн,
 страницы домена из выдачи → флаги ИНН/ОГРН/название + фрагменты
→ GigaChat-2-Max: вердикт по каждому кандидату + цитата-доказательство
→ правило; сайта нет → GigaChat предлагает до 3 новых запросов → 2-я итерация
→ `{"domain", "sites"}` + запись в справочник + трассировка `logs/<ИНН>.json`

Инструменты

Компонент	Выбор и причина
Карточка ЕГРЮЛ/ЕГРИП	API DaData <code>findById/party</code> . Нужны название и ОГРН для поиска и сверки, ФИО для ИП. В продакшене это join с внутренней таблицей реестра, без сетевого запроса; лимиты API DaData поэтому не учитывались.
Веб-поиск	Еха — возвращает полный текст страниц, поэтому карточки агрегаторов и страницы «Контакты» читаем без отдельной загрузки. DuckDuckGo (<code>ddgs</code>) — второй индекс, бесплатно; API неофициальный, сбои не ломают пайплайн.
Загрузка сайтов	<code>httpx</code> + <code>selectolax</code> (<code>lexbor</code> , сам определяет кодировку, в т.ч. windows-1251). Дедлайн 15 с на страницу, 30 с на сайт. Если сайт закрыт от ботов или почти пуст (JS) — текст через Еха contents.
LLM	GigaChat-2-Max , официальный SDK <code>gigachat</code> . Строгий JSON через function calling, <code>temperature=0</code> . TLS — с корневым сертификатом НУЦ Минцифры (проверку сертификата не отключал). Бесплатный тариф допускает один запрос одновременно: при параллельной обработке ИНН вызовы LLM идут через очередь.
Домены	<code>tlldextract</code> с офлайн-снимком Public Suffix List, включая приватную часть: <code>site.msk.ru</code> — самостоятельный сайт, а <code>shop.wixsite.com</code> сводится к домену платформы.

Ключевые технические решения

- Проверка реквизитов кодом до LLM.** ИНН/ОГРН ищутся регулярным выражением, с учётом пробелов («7721 581 040»). Это главный рычаг точности: факт, а не мнение модели.
- LLM даёт категорию, а не вероятность.** Вероятности, которые модель выдаёт словами, не откалиброваны. Вместо них — вердикт из фиксированного набора: `own_site` / `group_site` / `third_party_mention` / `unrelated`. Главная задача LLM — отличить собственный сайт от упоминания третьей стороной: на ИНН DaData поиск выдаёт десятки сайтов автодилеров, где «ООО "Дейта Кью"» — обработчик данных в политике ПДн.
- Вместо «reason» — цитата, которую проверяет код.** Свободное обоснование в ответе не нужно. Модель обязана привести фрагмент страницы, на котором основан вердикт. Код проверяет, что все числа из цитаты есть на странице и что не меньше 85% её слов встречаются в тексте страницы (без учёта пробелов: Еха отдаёт текст со склеенными словами). Дословное совпадение не требуется: модель переписывает таблицы реквизитов в списки, и при строгой проверке терялся верный `sberbank.ru`.

4. Прозрачное правило решения:

- принять, если ИНН или ОГРН есть на сайте и LLM подтвердила `own_site` или `group_site`;
- принять, если на сайте есть название, есть независимый источник (домен упомянут на странице с ИНН компании или совпадает с почтой из ЕГРЮЛ) и LLM подтвердила `own_site`;
- иначе — `null`.

Правило настраивается на размеченной выборке, каждое решение видно в трассировке.

- Без LangGraph.** Поток почти линейный: один цикл максимум из двух итераций и одна развилка. Всё, ради чего берут LangGraph, здесь не нужно: сохранение состояния, возобновление после сбоя, участие человека, параллельные ветки, несколько агентов. Обычный Python короче, логика видна целиком, меньше зависимостей.
- Workflow вместо автономного агента**, где LLM сама выбирает инструменты: предсказуемая стоимость (не больше 2 итераций, до 8 кандидатов на итерацию), воспроизводимость, качество легко измерить. Платим за это гибкостью в нестандартных случаях.
- Агрегаторы распознаются по общим признакам, а не по чёрному списку.** Агрегаторов сотни, список не бывает полным. Признаки «страницы-каталога»: ИНН или ОГРН компании в URL или заголовке, длинный числовой ID в пути (`/id/3197573`), четыре и больше разных ИНН на странице. Такие страницы не считаются доказательством для своего домена. Без этого `rusprofile.ru` выглядел бы «сайтом с ИНН компании» — так было в первой версии: 6 ложных срабатываний на 56 ИНН. Площадки (соцсети, маркетплейсы, бесплатная почта) получают низкий приоритет, но не исключаются: у Ozon, HeadHunter, Яндекса это и есть собственный сайт.
- Устойчивость к отказам GigaChat.** Фильтр модели срабатывал (`finish_reason=blacklist`) на пакете кандидатов, где была страница о санкциях, и ответ пропадал для всех кандидатов сразу. Теперь при отказе каждый кандидат оценивается отдельным запросом, отказ затрагивает только «чувствительную» страницу.
- Сбой поиска — это ошибка, а не null.** Если поисковик не ответил ни на один запрос, пайплайн возвращает ошибку и ничего не пишет в справочник. Иначе компания на 30 дней получила бы ложное «сайта нет». Ситуация реальная: во время работы Еха оказался недоступен без VPN.
- Справочник и кэш.**
 - `data/directory.csv` хранит и найденные сайты, и отрицательные ответы с датой проверки: «сайта нет» перепроверяется через 30 дней. Формат CSV выбран, чтобы справочник можно было открыть в Excel и перенести в другую систему одной загрузкой.
 - Ответы поиска, загруженные сайты и ответы LLM кэшируются на диске: повторные прогоны и сравнение режимов почти ничего не стоят и воспроизводимы.

Качество

Выборки: dev — 56 ИНН (на ней разбирались ошибки, метрики оптимистичны) и отложенная — 34 ИНН (для настройки не использовалась, главная оценка). Сегменты: крупные компании; малые ЮЛ и ИП с сайтом (найлены «от сайта к ИНН» через страницы реквизитов); случайные ЮЛ и ИП (подсказки DaData по частым словам, разные регионы); ликвидированные. Разметка — другой поисковик и ручная проверка сайта; 3 ИНН с неустановленным ответом исключены. Метрики по основному домену: *precision* — доля верных среди возвращённых; *recall* — доля найденных среди компаний с сайтом; *верные null* — доля `null` у компаний без сайта.

Отложенная выборка — главный результат:

Режим	precision	recall	верные null	accuracy	TP	FP	FN	TN	токенов/ИНН
полный пайплайн	95%	81%	100%	85%	21	1	4	8	5040
без 2-й итерации	95%	81%	100%	85%	21	1	4	8	3089
без LLM (только ИНН/ОГРН на сайте)	85%	85%	88%	85%	22	4	1	7	0

По исходной разметке было *precision* 73% / *recall* 62%: 5 из 6 «чужих» доменов оказались вторыми сайтами тех же организаций с их ИНН (в тб. рф, сайты гостиничной компании и её отеля, второй магазин ООО, второй домен ИП). Эталон «от сайта к ИНН» знает один сайт компании; эти домены добавлены после ручной проверки и помечены в `data/holdout.csv`.

Сегмент	n	precision	recall	верные null	TP	FP	FN	TN
крупные компании	6	80%	67%	—	4	1	1	0
малые/средние ЮЛ с сайтом	12	100%	83%	—	10	0	2	0
ИП с сайтом	8	100%	88%	—	7	0	1	0
случайные ЮЛ	5	—	—	100%	0	0	0	5
случайные ИП	3	—	—	100%	0	0	0	3

Dev-выборка (для сравнения):

Режим	precision	recall	верные null	accuracy	TP	FP	FN	TN	токенов/ИНН
полный пайплайн	97%	95%	100%	96%	36	1	1	18	4808
без 2-й итерации	100%	89%	100%	93%	34	0	4	18	3368
без LLM (только ИНН/ОГРН на сайте)	83%	79%	94%	84%	30	6	3	17	0

Выводы

- **LLM повышает точность:** без неё («на сайте есть ИНН/ОГРН — принять») precision 83–85% — принимаются агрегаторы, санкционные списки, тендерные площадки, чужие политики ПДн; с вердиктом LLM — 95–97%. На отложенной выборке цена — recall 85% → 81%.
- **Вторая итерация** (запросы от LLM) на dev подняла recall 89% → 95%, на отложенной не изменила ничего: эффект не подтверждён.
- **Компаниям без сайта сайт не приписан ни разу** (верные null — 100% на обеих выборках), включая ИП с тёзкой-писательницей и банкрота с реквизитами на чужом юридическом сайте.
- **Ошибки отложенной выборки** (не исправлялись, чтобы оценка оставалась честной): «Ашан» — принята страница тендерной площадки; пропуски: Wildberries и cifrus.ru (сайты на JS, бренд латиницей), sst72.ru (модель подмешала в цитату индекс из карточки), lomonosov.school (спорно: на сайте ИП лишь принимает платежи за ООО).
- **Стоимость ИНН:** медиана 76 с и ~4,5 тыс. токенов GigaChat, 3–6 запросов к Еха; вторая итерация — в ~40% случаев.
- **Ограничения оценки:** выборки малы (95%-й интервал Уилсона для precision 21/22 — 78–99%), положительные примеры малых компаний смещены к сайтам с реквизитами.

Ограничения и что улучшить

- **Поиск:** Еха и DuckDuckGo слабо покрывают малый бизнес РФ и доступны только через VPN → Yandex Search API.
- **Сайты на JS и защита от ботов** (Wildberries, Ашан): нужен headless-браузер; сейчас вырывают Еха contents и страницы из выдачи.
- **Бренды без реквизитов на сайте** подтверждаются плохо → WHOIS (владелец домена), товарные знаки, домены почты из ЕГРЮЛ (платные тарифы DaData).
- **Цитаты:** модель иногда подмешивает данные карточки → давать ей только фрагменты страниц или проверять числа карточки отдельно.
- **Один ИНН — много сайтов:** проверяется до 8 доменов за итерацию; полный список даст обход «от домена к ИНН» (Задание 1).